



MEMORIA DE LA COMPETICIÓN EN
KAGGLE
MÁSTER EN CIENCIA DE DATOS

Minería de Datos: Pre-procesamiento y clasificación.

Autores

José Ángel Díaz García, Wences, Álvaro Mateos Tiset, Gerardo



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE
TELECOMUNICACIÓN

Granada, Enero de 2018

Índice general

Índice de figuras

Índice de tablas

Capítulo 1

Introducción

En este primer capítulo de la memoria veremos en detalle la introducción al problema que se pedía resolver como parte de la evaluación práctica de la asignatura **Minería de Datos: Pre-procesamiento y clasificación**, enmarcada dentro del Máster en Ciencia de Datos de la Universidad de Granada.

1.1. Introducción

La reciente incursión de las técnicas de minería de datos en actividades cotidianas o diarias constatando sus innumerables aplicaciones en diversos dominios o problemas, han propiciado que de en año en año sean más los profesionales de sectores muy dispares que deciden formarse en estas tareas que les lleven a ostentar en un futuro próximo el título de científicos de datos. Este creciente interés ha propiciado también un caldo de cultivo perfecto para diversas plataformas online que ayudan a estos profesionales en su proceso de formación siendo una de las plataformas más conocidas Kaggle [?].

Esta plataforma, se basa en proponer problemas reales de minería de datos que cualquier persona interesada en la temática puede intentar resolver, en muchos casos sin grandes necesidades de computo o máquinas potentes. Esta plataforma evalúa los resultados aportados por cada participante y evalúa un ranking en función de diversas medidas de bondad, lo que la ha convertido también en una herramienta esencial entre los docentes del ámbito de la

ciencia de datos que la usan para enfrentar a sus alumnos con problemas reales de ciencia de datos. Esta memoria, se centra por tanto en detallar el proceso llevado a cabo por los autores para resolver un problema propuesto por los profesores de la asignatura en la plataforma Kaggle. El problema en cuestión, será definido en la siguiente sección.

1.2. Definición del problema

El problema propuesto para su resolución es un problema de clasificación que debería abordarse usando técnicas de pre-procesado y cuatro algoritmos de clasificación de diversas vertientes, a saber, reglas, árboles, vecinos más cercanos y regresión logística. El grueso por tanto del problema residirá en el proceso de pre-procesado de datos ya que los algoritmos que veremos en la sección ?? no admiten muchas modificaciones en sus parámetros.

El conjunto de datos de entrenamiento está formado por 2728 observaciones con 74 variables además de la clase catalogada como \mathbf{Y} y que puede tomar cuatro valores distintos (0,1,2,3). Las variables de entrenamiento, tienen todas valores numéricos continuos exceptuando las que se pueden ver en la siguiente tabla y que son strings con distintos dominios.

<i>Variable</i>	<i>Tipo</i>	<i>Dominio</i>
$x0$	string	VS, S, M, L , VL
$x14$	string	true / false
$x17$	string	way1, way2, way3...
$x51$	string	no / yes
$x63$	string	active / inactiva

Tabla 1.1: Variables no numéricas

Utilizando por tanto las variables descritas anteriormente, se crearán modelos que se usen para evaluar un conjunto de test de unas 600 observaciones sin etiquetar que serán las que Kaggle use para la obtención del valor de accuracy ¹ con el que se creará el ranking final.

¹Porcentaje de acierto.

1.3. Organización del trabajo

Tras esta introducción al problema y a la asignatura, los siguientes capítulos abordan el problema comenzando por la metodología y planificación del equipo seguida (capítulo ??), siguiendo por una detallada explicación del proceso de pre-procesado (capítulo ??) y finalizando con las conclusiones finales y un resumen del trabajo realizado (capítulo ??).

Capítulo 2

Metodología y planificación

En este capítulo se detallan los algoritmos usados durante los procesos siguientes así como la metodología de trabajo y desarrollo llevada a cabo por el equipo durante el transcurso de la práctica para favorecer mejores resultados y sobre todo optimizar tiempos.

2.1. Algoritmos utilizados

Los algoritmos propuestos para la realización de la práctica pertenecen a ramas dispares dentro del aprendizaje automático, estos son: Ripper, basado en reglas, 1-NN, basado en proximidad y similitud, Rpart basado en árboles y Glm, basado en regresión.

2.1.1. Ripper

El algoritmo RIPPER [?] es una extensión del algoritmo IREP (Incremental Reduced Error Pruning), que construye un set de reglas donde todos los ejemplos positivos son cubiertos, por lo que es bastante útil en problemas con muchos ejemplos y ruidosos. Se basa en la construcción de dos sets de reglas durante el proceso de aprendizaje, el set de crecimiento y el de podado, generando reglas con el primero.

2.1.2. Rpart

El algoritmo Rpart es un método basado en árboles [?] y que puede ser usado tanto para problemas de regresión como de clasificación. Como en todos los métodos basados en árboles, se generan particiones en los datos en función de las variables que se usan para clasificar. La diferencia de este método radica en que es recursivo y cada una de las particiones puede volver a tenerse en cuenta como parte de otra partición hasta que se alcancen los criterios de parada.

2.1.3. 1NN

El algoritmo KNN [?] está englobado dentro de los algoritmos de *Lazy Learning* y se basa en la similitud entre instancias. Hace uso de diversas medidas de distancia, como por ejemplo la euclídea, para determinar el número de ejemplos de cada clase que se encuentran a una distancia determinada del ejemplo a clasificar. Cada uno de los ejemplos de una determinada clase, corresponden con un "voto" para esa clase, finalmente la clase asignada será la que más votos tenga.

2.1.4. Glm

El algoritmo GLM [?] es una generalización del algoritmo de regresión lineal que permite ser aplicado en problemas con variables que no siguen distribuciones normales. Puede usarse tanto para clasificación como para regresión y solo acepta dos clases de salida por lo que los problemas deben descomponerse en binarios para poder aplicar GLM sobre ellos en el caso de ser utilizado para clasificación. El algoritmo, propone una combinación de técnicas típicas de regresión lineal, regresión logística y regresión de poisson.

2.2. Metodología de trabajo

Cualquier trabajo en equipo debe conllevar una buena planificación para conseguir buenos resultados en las etapas finales de cualquier proceso. Si además el ámbito de aplicación es la informática una correcta planificación

es de vital importancia para llevar el proyecto a buen fin. En esta sección veremos por tanto algunos puntos claves en la coordinación y planificación del equipo de trabajo.

2.2.1. Planificación temporal

El proyecto ha sido planificado temporalmente acorde a los siguientes puntos, tareas u objetivos:

- **Pruebas con modelos individuales:** En los primeros días, se dividieron los algoritmos de manera que cada miembro pudiera explotar los puntos fuertes y débiles de su algoritmo para el problema de manera que en puntos siguientes se potenciara solo el mejor algoritmo de los 4 para el problema en cuestión.
- **Pruebas con todos los modelos:** Una vez estudiado el algoritmo asignado para cada miembro del equipo, se llevó a cabo una batería de pruebas en las que con base en los resultados individuales obtenidos se probaron los de los demás.
- **Optimización:** Una vez encontramos un modelo de pre-procesado y algoritmo que se comportaba bien, se explotó el mismo con diversas combinaciones y pruebas.
- **Reuniones de grupo:** Reuniones de puesta en común de resultados y debate de técnicas y vías de estudio.
- **Redacción:** Tras la finalización de la competición se abre un período de redacción del presente documento.

En la figura ??, puede verse un croquis sobre el calendario de los meses de enero-marzo, en el que se detallan las distintas tareas que se han detallado en puntos anteriores.

Semana	L	M	X	J	V	S	D
1	22	23	24	25	26	27	28
2	29	30	31	1	2	3	4
3	5	6	7	8	9	10	11
4	12	13	14	15	16	17	18
5	19	20	21	22	23	24	25
6	26	27	28	1	2	3	4

Pruebas con modelos individuales	Pruebas con todos los modelos	Optimización	Redacción	Reuniones de grupo
----------------------------------	-------------------------------	--------------	-----------	--------------------

Figura 2.1: Croquis de la planificación seguida.

2.2.2. Desarrollo

Para el desarrollo del código se ha usado un repositorio privado para el control de versiones en GitHub, con ramas para cada uno de los miembros del equipo que eran fusionadas al realizar algún avance por parte de cada uno de los implicados.

Dado que el proceso de pre-procesado de datos es incremental y secuencial, se ha llevado a cabo un desarrollo basado en **soluciones intermedias**. Con este método, se guardan soluciones intermedias que son etiquetadas con el pre-procesado aplicado de manera que estas pueden ser usadas por otro miembro del equipo sin necesidad de tener que aplicar técnicas que otro miembro ya uso. Este método ha permitido ahorrar en tiempos de ejecución así como tener constancia de que técnicas estaban dando mejor resultados que otras para su posterior refinamiento.

Capítulo 3

Proceso exploratorio y pre-procesado

En este capítulo veremos el proceso seguido para afrontar y resolver el problema definido en puntos anteriores. El capítulo comienza detallando el proceso exploratorio inicial para continuar con el grueso de la memoria, la especificación de los procesos de pre-procesado llevados a cabo y la solución final aportada.

3.1. Proceso exploratorio

3.2. Pre-procesado

3.3. Técnicas de clasificación

3.4. Solución aportada

Capítulo 4

Conclusión

En este capítulo se concluye el trabajo aportando un pequeño resumen al proceso realizado así como a los objetivos alcanzados con el mismo y la solución final aportada. Se finaliza el capítulo, con una serie de valoraciones personales sobre el proceso llevado a cabo.

4.1. Resumen

4.2. Conclusiones finales

Bibliografía

- [1] Web del portal Kaggle <https://www.kaggle.com>. Accedido el 1 de marzo de 2018.
- [2] Johannes Furnkranz, Gerhard Widmer: Incremental Reduced Error Pruning. *Proceedings of the 11th International Conference on Machine Learning (ML-94)*, pp. 70-77, New Brunswick, NJ, 1994. Morgan Kaufmann.
- [3] L. Breiman, J.H. Friedman, R.A. Olshen, , and C.J Stone. *Classification and Regression Trees*. Wadsworth, Belmont, Ca, 1983
- [4] T.M. Cover, P.E.Hart. Nearest Neighbor Pattern Classification. *IEEE* (1967)
- [5] Nelder, John; Wedderburn, Robert (1972). Generalized Linear Models. *Journal of the Royal Statistical Society*. 135 (3): 370?384.